FASE 1 — SELECCIÓN JUSTIFICADA DEL AGENTE

Matriz de Decisión Ponderada y Análisis Comparativo

- **Estudiantes (Pareja de trabajo):**
- Jesús Andrés Pérez Fuentes (T00078491) — *TrafficFlow-Agent*
- Cristian David Cardeño Gulloso (T00078446) — *SegmentIQ-Agent*
- **Curso:** Inteligencia Artificial — Universidad Tecnológica de Bolívar (UTB)
- **Docente:** Edwin Alexander Puertas Del Castillo
- **Fecha:** Octubre de 2026
- **Repositorio:** https://github.com/Jxzus/TRAFFICFLOW-AGENT

1. Definición de Criterios y Ponderación Inicial (Paso 1)

2. Matriz de Decisión Ponderada (Paso 2 y Paso 3)

Criterio	Peso (w)	Agente A (TrafficFlow-Agent): puntaje (1–5)	Agente A: evidencia	Agente B (SegmentIQ-Agent): puntaje (1–5)	Agente B: evidencia
Viabilidad técnica	25 %	5	El equipo domina PyTorch y series temporales viales; la arquitectura Graph WaveNet y su entrenamiento ya cuentan con pipeline modular funcional.	4	K-Means y RFM son directos de implementar con Scikit-Learn, pero simular la retroalimentación de compra del cliente requiere modelar comportamiento humano estocástico complejo.
Disponibilidad de datos o entorno	20 %	5	Dataset benchmark abierto `METR-LA` disponible localmente (207 sensores, 34.272 registros de 5 min) junto con simulador sintético estocástico funcional (`TrafficEnvironment`).	4	Dataset público transaccional disponible (`Online Retail` de UCI), pero no cuenta con un simulador dinámico de interacción ni respuesta a campañas.
Medibilidad	20 %	5	Medidas con fórmula	3	La meta SMART

del desempeño			matemática rigurosa (MAPE y MAE a 30 min) verificables objetivamente contra datos reales cada 5 min y probadas en 10 escenarios.		exige medir "+15% en tasa de respuesta a campañas comerciales en 3 meses", lo cual es inviable de probar experimentalmente sin un e-commerce real activo.
Complejidad de IA	15 %	5	Agente basado en modelo con aprendizaje: combina Graph WaveNet (convoluciones causales dilatadas + difusión adaptativa sobre grafos), z-scores históricos y recalibración continua por deriva.	3	Segmentación no supervisada tradicional (K-Means y RFM); opera más como un pipeline analítico mensual por lotes (batch ETL) que como un agente reactivo continuo percepción-acción.
Costo y recursos	10 %	4	0 COP en APIs de pago; requiere cómputo local con PyTorch (ejecutable en CPU/GPU doméstica en pocos minutos gracias a su diseño compacto).	5	0 COP en APIs; clustering K-Means corre en segundos en cualquier computador con requerimientos mínimos de memoria.
Valor del problema	10 %	5	Aborda una problemática crítica de interés público en ciudades colombianas (congestión vial urbana, tiempos de viaje, emisiones de CO_2 y control semafórico).	4	Solución comercialmente atractiva para focalizar presupuestos de mercadeo en retail, pero de beneficio circunscrito al ámbito privado corporativo.
Puntaje ponderado S	100 %	4.90	$S(A) = 0.25(5) + 0.20(5) + 0.20(5) + 0.15(5) + 0.10(4) + 0.10(5) = \mathbf{4.90}$	3.75	$S(B) = 0.25(4) + 0.20(4) + 0.20(3) + 0.15(3) + 0.10(5) + 0.10(4) = \mathbf{3.75}$

3. Análisis de Sensibilidad (Paso 4)

Caso A: Incremento de peso (+10 puntos $\to w_1 = 35\%$)

- $w_{\text{Viabilidad}} = 0.35$
- Los demás criterios absorben el ajuste proporcional: $w_{\text{Datos}}=0.1733$, $w_{\text{Medibilidad}}=0.1733$, $w_{\text{Complejidad}}=0.1300$, $w_{\text{Costo}}=0.0867$, $w_{\text{Valor}}=0.0867$.
- **Cálculo:**
- **Resultado:** TrafficFlow-Agent mantiene una ventaja contundente de $+1.13$ puntos.

Caso B: Reducción de peso (-10 puntos $\to w_1 = 15\%$)

- $w_{\text{Viabilidad}} = 0.15$
- Criterios restantes ajustados proporcionalmente: $w_{\text{Datos}}=0.2267$, $w_{\text{Medibilidad}}=0.2267$, $w_{\text{Complejidad}}=0.1700$, $w_{\text{Costo}}=0.1133$, $w_{\text{Valor}}=0.1133$.
- **Cálculo:**
- **Resultado:** TrafficFlow-Agent amplía su ventaja a $+1.17$ puntos.

4. Redacción de la Justificación de Selección (Paso 5 — Máximo una página)

- Percibe un entorno dinámico continuo cada 5 minutos.
- Mantiene un estado interno enriquecido (grafo de conectividad vial y memoria de corto/largo plazo).
- Pronostica a 30 minutos combinando redes neuronales espaciotemporales (Graph WaveNet) con perfiles históricos de z-score.
- Actúa de forma cerrada sobre controladores semafóricos y paneles de información vial aplicando políticas de estabilización.
- Aprende y se recalibra ante derivas conceptuales del tráfico cuando el componente de crítica detecta degradación del error.

¿Qué se pierde al descartar SegmentIQ-Agent?